

北京大学 2026–2027 学年春季学期

量化交易

第一次小组报告

基于机器学习的合成因子策略研究

授课教师：吴岚

第 7 组 王瑾琛 陈云豪

2026 年 4 月

摘要

摘要

本文旨在探索机器学习算法在量化因子合成中的应用，构建了一套基于 Stacking 的动态滚动合成因子策略。研究首先对初始因子池进行单因子有效性检验，通过 IC、ICIR 指标及互信息（Mutual Information）分析，筛选出涵盖收益率反转、估值回归及流动性溢价等维度的 10 个核心因子。

针对 A 股市场明显的非线性特征与风格快速轮动现象，本文提出并实现了一个双层 Stacking 集成框架：底层采用 XGBoost 与 LightGBM 进行预测，顶层利用逻辑回归进行线性权重优化。最终采用了“一年半训练—5 个月验证—5 个月测试”的动态滚动窗口，以确保模型对市场环境的实时自适应。结果显示合成因子策略在累积 IC 上要远高于单因子策略。净值回测也有较高的超额收益，净值曲线高于其他单因子策略与沪深 300 基准。这说明在 A 股市场利用机器学习进行因子合成在某种程度上是可行的。

关键词：因子合成；集成学习；LightGBM；XGBoost

目录

插图索引	3
1 引言	4
1.1 研究目的	4
1.2 策略基本设定	4
1.3 数据说明	4
1.4 模型介绍	4
2 单因子测试	5
2.1 因子介绍	5
2.1.1 数据来源及处理	5
2.1.2 因子检验指标	6
2.1.3 因子指标筛选结果	6
2.1.4 基于互信息的因子剔除	8
2.1.5 因子相关性检验	9
3 基于 Stacking 的因子合成	11
3.1 数据预处理与标签构建	11
3.2 模型介绍	12
3.3 模型结果	14
3.3.1 特征贡献度	15
3.3.2 SHAP 局部解释分析	16
3.4 回测结果	17
4 结论	21
参考文献	22

插图索引

1	因子筛选训练集累积 IC 曲线	7
2	因子筛选测试集累积 IC 曲线	7
3	互信息评估展示	9
4	因子相关性	10
5	滚动窗口回测方案示意图 (2015-2022)	12
6	模型流程图	13
7	模型各置信度分组预测性能	15
8	LightGBM 特征贡献度	15
9	XGBoost 特征贡献度	16
10	LightGBM SHAP 摘要图	16
11	XGBoost SHAP 摘要图	17
12	合成因子累积 IC	18
13	按模型置信度分组的平均周收益率净值曲线图	18
14	top-30 策略累积净值	19

第一章 引言

1.1 研究目的

基于现有的基本因子库和我们自己构建的一些因子生成新因子并构建投资策略，掌握主要的基于已有因子生成新因子的方法。

1.2 策略基本设定

- 股票池：20260120 沪深 300 指数成份股
- 调仓频率：周频，期间不做任何操作
- 数据区间：因子筛选训练集 20160101-20201231，因子筛选测试集 20210101-20221231，机器学习合成因子训练集 20160101-20221231，机器学习合成因子测试集 20230101-20260120，其中机器学习部分采用了滚动建模
- 初始资金：1 单位
- 交易设定：
 - 交易费用设置为 0
 - 以调仓日的收盘价作为成交价

1.3 数据说明

- 数据来源：课程提供的因子数据，课程提供的沪深 300 股票数据；
- 基准市场指数：沪深 300 指数；
- 数据处理：在各部分详述。

1.4 模型介绍

基本思路为在因子筛选训练集上利用 IC、ICIR 寻找最优的因子，并剔除相关性高的因子，将得到的最优因子利用机器学习滚动建模合成，并观察合成后的新因子的表现。

第二章 单因子测试

为了选出有逻辑意义并且能够有效的区分个股的因子,使得因子值对于个股未来收益有一定的预测能力,我们进行了单因子有效性检验,检验策略设定如下:

- 股票池: 沪深 300 指数在 2026-01-20 的成分股
- 调仓频率: 周频
- 测试集: 201601101-20201231

我们对因子在测试集上进行了 IC 值检验和 ICIR 检验来检验因子的有效性,筛选出了 11 个最佳因子。再进一步采用互信息剔除无效因子。

2.1 因子介绍

2.1.1 数据来源及处理

表 1: 初始因子池分类

类别	因子说明	类别	因子说明
收益率	20 日收益率标准差反转 [5/20/30/60/120] 日收益率反转 120 日收益率动量 过去 5 日涨跌幅反转 20 日乖离率反转	盈利	营业利润 / 营业总收入 净资产收益率 (ROE) 及其变换 总资产收益率 (ROA) 销售净利率 销售毛利率 每股收益 (EPS)
换手率	[10/20] 日换手率标准差反转 [1/5/30/60/120] 日平均换手率反转	估值	盈利收益率 (1/PE) 账面市值比 (1/PB) 及其变换
大小单	特大单净流出比例 特大单净占比反转	研报	知情交易者因子
规模	对数总市值 对数流通市值 [10/20] 日市值变化率反转	成长	营收/总营收同比增长 净利润/归母净利润同比增长 营业利润同比增长
杠杆	流通市值 / 总市值 流通股本 / 总股本		

因子数据来源包括课程提供因子与券商研报。上面的表格展示了进入我们初步筛选步骤的所有因子。由于原始数据中存在缺失值及异常值,为保证因子检验结果的可靠性,我们对数据进行了缺失值处理,对因子结果进行了去极值处理。

- 在计算因子与收益率相关性 (IC) 时,采用逐截面剔除法,即在每一个调仓时点,仅对同时具有因子值和未来收益率的股票进行计算,其余样本直接剔除;
- 去极值: 因子值应当满足一个合理的分布区间,在数据搜索和计算的过程中,可能

会产生异常值, 影响后续研究, 因此需要在截面上对因子的极端值进行处理。我们采用对截面进行 MAD 去极值 (去除距离均值大于 3 被标准差的因子值)。

2.1.2 因子检验指标

• IC 分析

IC (Information Coefficient), 即信息系数, 是最常用的因子有效性检验指标之一。对于一个给定因子, 其在 t 时刻的 IC 定义为该时点股票在该因子上的因子暴露 X_t 与 t 至 $t+1$ 时间区间内股票收益率 R_{t+1} 之间的相关系数, 即:

$$IC_t = \text{corr}(X_t, R_{t+1})$$

IC 反映了因子在截面上对未来收益的解释能力, 其绝对值越大, 说明因子对股票收益的区分能力越强。然而在实际市场中金融数据中普遍存在噪声及极端值, 使得 Pearson 相关系数的稳健性较差。因此, 本文采用 Spearman 秩相关系数来替代 Pearson 相关系数。Spearman 秩相关系数是将因子暴露与收益率在截面上分别进行排序, 以排序后的位次替代原始数值后计算得到的相关系数, 其本质上刻画的是变量之间的单调关系。IC 均值刻画了因子的平均预测能力, 其值越大, 说明因子整体选股能力越强。

• ICIR 分析

仅通过 IC 均值无法全面评价因子的优劣, 因此通常结合 IC 的波动性进行综合评估。为此, 我们对因子筛选加入了 ICIR (Information Coefficient Information Ratio) 指标检验, 其定义为:

$$ICIR = \frac{\overline{IC}}{\sigma_{IC}}$$

ICIR 可以理解为单位波动下的平均信息系数, 其含义类似于收益评价中的夏普比率。ICIR 越大, 说明因子在获得较高平均预测能力的同时, 其表现也更加稳定。

- 因此, 在本研究中的因子初步筛选逻辑为: 在因子筛选训练集先调试参数使在训练集的 IC 与 IR 表现尽可能好并且保持 IC 方向基本一致。其次再在训练集上测试因子, 保留测试集表现好的因子。

2.1.3 因子指标筛选结果

经过 IC 与 ICIR 的筛选最终得到如下 11 个因子。

表 2: 因子指标筛选结果

因子	类别	说明	覆盖率
alpha_ret_mean	收益率	20 日平均收益率反转	99.9%
alpha_ret_std	收益率	20 日收益率标准差反转	99.8%
alpha_tvr_mean	换手率	10 日平均换手率反转	100.0%
alpha_tvr_std	换手率	20 日换手率标准差反转	99.9%
alpha_xl	大小单	特大单净流出比例	98.5%
alpha_cap	规模	对数流通市值	100.0%
alpha_cap_pct	规模	20 日市值变化反转	98.3%
val_float2tot	杠杆	流通市值/总市值	100.0%
alpha_profit	盈利	营业利润/营收	100.0%
alpha_eval_pe	估值	盈利收益率	100.0%
alpha_info	研报	知情交易者因子	99.0%

筛选所保留的因子覆盖多个维度，包括收益率、换手率、规模、估值、盈利能力以及行为类因子等，具有较好的多样性。这种多维度因子结构有助于从不同角度刻画股票特征，从而提升后续合成因子模型的综合预测能力。大部分因子的覆盖率均在 98% 以上，数据完整性较高，能够有效支持后续建模与回测分析。




图 1: 因子筛选训练集累积 IC 曲线




图 2: 因子筛选测试集累积 IC 曲线

如上，我们展示了 11 个最佳因子的累积 IC 表现，为了更好地判断因子在训练集和

测试集的稳定性，我们对因子策略的换手率也进行了统计。

表 3: 训练集因子指标

因子名称	IC	IR	换手率 (tvr)
20 日换手率标准差反转	0.0496	0.2630	17.26%
10 日平均换手率反转	0.0411	0.2029	16.80%
对数流通市值	0.0375	0.2009	0.62%
知情交易者因子	0.0371	0.3695	50.30%
20 日收益率标准差反转	0.0277	0.1351	12.84%
盈利收益率 EP=1/PE	0.0258	0.1360	3.81%
20 日市值变化反转	0.0245	0.1391	72.94%
20 日平均收益率反转	0.0244	0.1368	72.38%
营业利润 / 营收	0.0199	0.1619	2.92%
流通市值 / 总市值	0.0125	0.2053	0.21%
特大单净流出比例	0.0082	0.0752	137.23%

表 4: 测试集因子指标

因子名称	IC	IR	换手率 (tvr)
10 日平均换手率反转	0.0639	0.3433	14.96%
20 日换手率标准差反转	0.0603	0.3575	15.97%
20 日收益率标准差反转	0.0493	0.2324	11.72%
20 日平均收益率反转	0.0288	0.1494	70.40%
盈利收益率	0.0286	0.1240	4.07%
20 日市值变化反转	0.0267	0.1391	70.00%
特大单净流出比例	0.0226	0.1619	135.59%
流通市值 / 总市值	0.0111	0.1831	0.21%
对数流通市值	0.0084	0.0593	0.64%
知情交易者因子	0.0082	0.0959	47.14%
营业利润 / 营收	0.0069	0.0596	2.34%

2.1.4 基于互信息的因子剔除

在量化因子筛选过程中，传统的线性相关系数（如 IC）仅能捕捉因子与收益率之间的线性关系。考虑到金融市场的复杂性，因子与收益率之间可能存在显著的非线性依赖。为此，本研究引入信息论中**互信息 (Mutual Information, MI)** 指标，以衡量因子对未来收益率预测能力的非线性贡献。基于互信息的因子筛选同时也符合我们后面采用的梯度提升树模型的非线性特质。

互信息 $I(X; Y)$ 用于衡量随机变量 X 与 Y 之间的相关性，其本质是衡量已知 X 的信息后， Y 的不确定性减少的程度。其计算公式为：

$$I(X; Y) = \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} P(x, y) \log \left(\frac{P(x, y)}{P(x)P(y)} \right) \quad (1)$$

其中：

- $P(x, y)$ 是因子 X 与标签 Y 的联合概率分布；
- $P(x)$ 和 $P(y)$ 分别是 X 和 Y 的边缘概率分布。

逻辑实现：

1. **标签离散化**：为了将问题转化为分类评估任务，我们对每周的收益率进行截面处理。以当周收益率的中位数为基准，将超过中位数的股票标记为 1，低于中位数的标记为 0。
2. **因子离散化**：由于原始因子值是连续变量，直接计算概率密度较为困难。代码采用了等频分箱的方法，将每个因子按分位数划分为 10 个区间 (Bins)，用离散变量来模拟。




图 3: 互信息评估展示

根据图 3, 剔除互信息最低的 `alpha_xl`(特大单净流出比例) 因子, 采用剩余的最终十个因子进行因子合成。

2.1.5 因子相关性检验

为了评估选定因子的独立性以避免选取的因子相关性过高的影响, 本研究计算了因子筛选的整个建模区间 (即 20160101-20221231) 的截面 Spearman 相关系数均值。




图 4: 因子相关性

相关系数较高的因子组合有：

- 20 日换手率标准差反转因子与 10 日平均换手率反转因子间相关系数为 0.91。
- 20 日市值变化反转因子与 20 日收益率标准差反转因子的相关系数为 0.98。
- 20 日收益率标准差反转因子与 10 日平均换手率反转因子的相关系数为 0.63。
- 20 日收益率标准差反转因子与 20 日换手率标准差反转因子的相关系数为 0.64。

其余因子间的相关系数均较低。为此我们考虑去掉这几对因子组合中每对中因子互信息值较低的那个。但是去掉这几个因子后的因子集合在后续机器学习模型建模的表现上不佳。因此我们选择将这一步剔除的因子加回到因子集合。

第三章 基于 Stacking 的因子合成

在股票市场中，传统的线性合成方法（如等权法或 IC 加权法）捕捉因子间复杂非线性交互特征的效果不佳，且容易受到因子多重共线性的影响。为此，本章引入集成学习的 Stacking，通过构建动态滚动的模型架构，实现对多维因子的深度合成。

3.1 数据预处理与标签构建

1. **截面分类标签：**在每个周五（ T 时刻），我们观察全样本个股在未来一周（ $T+1$ 时刻）的收益率 $r_{i,T+1}$ ，并以其截面中位数为阈值构建二分类标签：

$$y_{i,T+1} = \begin{cases} 1, & \text{if } r_{i,T+1} > \text{median}(\{r_{j,T+1}\}_{j=1}^N) \\ 0, & \text{otherwise} \end{cases} \quad (2)$$

2. **滚动逻辑配置：**尝试了如下的滚动方式，最终选择建模区间 f1-score 和 report 整体最佳的一种：

- 6 个月-3 个月-3 个月
- 80 周-20 周-20 周
- 两年-半年-半年
- 三年-半年-半年
- 四年-半年-半年
- 五年-一年-半年

表 5: 模型超参数设定与搜索范围

超参数	搜索范围	说明
max_depth	{3, 4, 5}	树的最大深度，控制模型复杂度
learning_rate	{0.05, 0.1}	学习率
n_estimators	{50, 100}	基学习器数量
cv (Stacking)	3	Stacking 内部交叉验证折数
元学习器	LogisticRegression (默认参数)	L2 正则化, C=1.0

注：本实验共计 12 组超参组合，在每个滚动窗口内，模型会根据验证集的准确率表现选择最优组合。

经过多轮实验验证，我们最终选取了“一年半（80 周训练）—5 个月（20 周验证）—5 个月（20 周测试）”的滚动组合。该配置在 f1-score 和 report 表现最佳。




图 5: 滚动窗口回测方案示意图 (2015-2022)

3.2 模型介绍

本研究构建的 Stacking 集成系统并非简单的模型堆叠，而是一个旨在通过“偏差-方差”权衡提升 Alpha 稳健性的层级化架构。其核心设计包含两个基学习层与一个元学习层。

为了确保模型能够从因子数据中捕捉到互补的非线性规律，我们选取了两种基于不同优化路径的梯度提升树算法：

1. XGBoost: XGBoost 算法的目标函数表示为：

$$\mathcal{L}^{(t)} = \sum_{i=1}^n \left[l(y_i, \hat{y}_i^{(t-1)}) + g_i f_t(\mathbf{x}_i) + \frac{1}{2} h_i f_t^2(\mathbf{x}_i) \right] + \Omega(f_t) \quad (3)$$

其中， g_i 和 h_i 分别为损失函数的一阶和二阶导数。在噪声巨大的因子数据中，二阶导数信息能更精准地定位梯度下降方向，而显式的正则化项 $\Omega(f) = \gamma T + \frac{1}{2} \lambda \|\omega\|^2$ 则有效抑制了因单一异常样本导致的模型剧烈波动，表现出极强的防御性

2. LightGBM: 相较于 XGBoost，LightGBM 侧重于计算效率与局部特征的深度挖掘：这种非对称的生长方式能捕捉到更高阶的非线性特征。配合其独特的 *GOSS*（基于梯度的单侧采样）算法，模型能够自动过滤掉梯度较小的平庸样本，将“注意力”集中在具有高 Alpha 潜力（大梯度）的个股上，对因子的细微变化捕捉更为灵敏。

模型的具体执行流程逻辑如下：

1. **特征生成:** 在每个滚动窗口中，我们将训练集数据进一步划分为多个折叠子集。XGBoost 与 LightGBM 分别在当前窗口的训练区间完成参数估计。随后，通过将验证集特征向量 $\mathbf{X}_{val}$ 投影至已训练的模型算子中，获得各模型的预测概率输出 $\mathbf{P}_{XGB}$ 与 $\mathbf{P}_{LGB}$ 。此
2. **特征重构与降噪:** 原始的 10 维因子特征在经过第一层基学习器的处理后，被压缩

为表征不同算法归纳偏好的二元概率向量。这通过树结构的递归切分，将隐含的因子间二阶交互项以概率的形式表现在特征中。

3. **决策：**元学习层采用 Logistic Regression (LR) 对上述概率向量进行参数化拟合。其目标是在极低维的元特征空间内寻找全局最优决策边界：

$$y_{final} = \phi(\omega_0 + \omega_1 P_{XGB} + \omega_2 P_{LGB}) \quad (4)$$

其中 $\phi(z) = (1 + e^{-z})^{-1}$ 为逻辑映射函数。系数 ω_k 的估计值反映了在当前滚动窗口所代表的抽样分布下，不同算法模型预测一致性的统计权重。




图 6: 模型流程图

选择这两个梯度提升树的算法则是基于以下理由：

1. 树类集成模型在多因子选股中表现最佳：研报²³⁴中的多项实证表明，以 XGBoost、LightGBM 和随机森林为代表的树类集成学习模型，其超额收益和信息比率通常显著优于支持向量机 (SVM)、朴素贝叶斯、逻辑回归以及浅层神经网络。
2. 运算效率高：LightGBM 和 XGBoost 在兼顾极高预测准确率的同时，运算速度具有明显优势，通常是随机森林或 AdaBoost 等其他集成算法的数倍。
3. 对数据量要求适中：我们使用的是周频滚动（过去 80 周训练），整体数据量属于中低频。研究发现，在月频/周频等多因子数据量较小的场景下，基于决策树的模型（XGBoost/LightGBM）表现通常优于以 LSTM 为代表的深度神经网络模型。

3.3 模型结果

表 6: 滚动窗口模型性能与最优超参数

测试起始日	训练集准确率	验证集准确率	测试集准确率	测试集 F1	深度	学习率	数量
2023-02-03	0.5475	0.5136	0.5388	0.5388	3	0.05	50
2023-06-23	0.5491	0.5388	0.5303	0.5201	3	0.05	50
2023-11-17	0.5582	0.5348	0.5643	0.5635	3	0.05	50
2024-04-12	0.5556	0.5457	0.5302	0.5302	3	0.05	50
2024-08-30	0.5601	0.5327	0.5068	0.4917	3	0.05	50
2025-01-17	0.6578	0.5197	0.5254	0.5239	5	0.10	100
2025-06-06	0.6597	0.5248	0.4876	0.4876	5	0.10	100
2025-10-24	0.6598	0.4909	0.4923	0.4920	5	0.10	100

表 7: 模型训练集表现

类别/指标	Precision	Recall	F1-score	Support
0 (跌)	0.51	0.52	0.51	38,481
1 (涨)	0.51	0.50	0.51	38,341
Accuracy	—		0.51	76,822
Macro Avg	0.51	0.51	0.51	76,822
Weighted Avg	0.51	0.51	0.51	76,822

表 8: 模型测试集表现

类别/指标	Precision	Recall	F1-score	Support
0 (表现较弱组)	0.51	0.51	0.51	61,968
1 (表现较强组)	0.51	0.51	0.51	61,968
Accuracy	—		0.51	123,936
Macro Avg	0.51	0.51	0.51	123,936
Weighted Avg	0.51	0.51	0.51	123,936

上述统计结果验证了模型在 12.4 万次测试样本中具备一定的正向预测边际。为了研究模型的预测能力主要在哪里，我们对模型结果各置信度进行了分组计算预测准确率。




图 7: 模型各置信度分组预测性能

可以发现模型的预测能力集中在两端，且最不看好的 20% 与 20%-40% 差异并不显著。由于作业要求使用多头策略，我们在后续的投资策略构建上选择了仅持有合成因子得分最高的 Top-30 只股票，实际利用的正是模型预测能力最强的区域。

然而，仅关注准确率等宏观指标难以揭示模型捕捉到的市场逻辑。下面我们会依次展示特征贡献度与 SHAP 局部解释（SHAP Explanations）。

3.3.1 特征贡献度




图 8: LightGBM 特征贡献度




图 9: XGBoost 特征贡献度

尽管 LightGBM 与 XGBoost 的底层算法逻辑不同,但两者对核心因子的判定具有高度的一致性。两个模型前四重要的特征集合相同。构成模型的基本盘基本一致。低信噪比下的信息提取:排名靠前的因子多具有显著的反转特征或估值回归逻辑。这说明集成模型成功识别了 A 股截面中一定的反转效应,并将其作为主要的超额收益来源。

3.3.2 SHAP 局部解释分析

为了进一步洞察模型,我们引入了 SHAP 值分析。




图 10: LightGBM SHAP 摘要图




图 11: XGBoost SHAP 摘要图

如图所示，换手率类因子与收益率反转因子占据了显著的特征重要性，说明模型主要依赖流动性溢价进行选股。散点图显示收益率标准差的高因子值与换手率均值反转的低因子值均分布在 SHAP 的正值区，代表模型确实捕捉到了高波动时买入的行为。

3.4 回测结果

表 9: 合成因子与各单因子表现对比（测试集）

因子名称	IC	IR	换手率 (tvr)
Stacking 合成因子	0.0658	0.3082	2.24%
等权合成因子	0.0539	0.2402	34.76%
20 日收益率标准差反转	0.0538	0.2138	12.83%
20 日换手率标准差反转	0.0491	0.2022	16.66%
10 日平均换手率反转	0.0490	0.1935	15.10%
盈利收益率 (EP)	0.0485	0.2052	3.63%
对数流通市值	0.0262	0.1420	0.53%
知情交易者因子	0.0177	0.1750	48.02%
营业利润 / 营收	0.0174	0.1318	2.45%
20 日平均收益率反转	0.0041	0.0191	70.93%
20 日市值变化反转	0.0021	0.0096	71.57%
流通市值 / 总市值	0.0019	0.0252	0.27%




图 12: 合成因子累积 IC

在长达三年的样本外测试中，Stacking 合成因子的均值 IC 达到了 6.58。从累积 IC 对比图可以发现, 合成因子的累积 IC 不仅稳定地高于 10 个单因子单独的累积 IC，也高于对 10 个因子做等权合成得到因子的累积 IC。统计结果进一步夯实了本研究的方法论有效性。

在考察我们多头使用的 top-30 股票策略之前，我们先对模型以置信度分为的 5 组股票先进行累积净值曲线与平均周收益率的刻画。




图 13: 按模型置信度分组的平均周收益率净值曲线图

此时多空组合，也就是做多第五组做空第一组的年化收益为 12.74%，周均收益 0.231%。可以方向策略效果受到了空头部分的影响。空头的第一组和第二组正如前面的检验一样差异不大且效果一般，接下来我们回测取前 30 高因子值股票的多头策略。



图 14: top-30 策略累积净值

表 10: 测试集策略绩效指标对比

因子/基准	日收益率	日收益率标准差	年化收益率	夏普比率	最大回撤
Stacking 合成	0.0767%	0.8686%	21.31%	1.35	-12.11%
10 日平均换手率反转	0.0552%	0.8821%	14.91%	0.87	-15.25%
20 日收益率标准差反转	0.0522%	0.8294%	14.06%	0.86	-11.78%
20 日换手率标准差反转	0.0542%	0.8847%	14.62%	0.85	-12.76%
知情交易者因子	0.0584%	1.1963%	15.84%	0.69	-22.91%
盈利收益率 EP=1/PE	0.0477%	1.0000%	12.76%	0.63	-17.79%
对数流通市值	0.0463%	0.9929%	12.38%	0.61	-17.00%
营业利润/营收	0.0338%	0.9835%	8.89%	0.39	-15.85%
等权合成因子	0.0312%	0.8670%	8.17%	0.39	-10.98%
沪深 300 基准	0.0319%	1.0704%	8.37%	0.33	-24.80%
流通市值/总市值	0.0313%	1.1048%	8.20%	0.31	-25.64%
20 日市值变化反转	0.0241%	1.4050%	6.25%	0.16	-36.06%
20 日平均收益率反转	0.0203%	1.4022%	5.25%	0.11	-36.94%

- **卓越的超额收益：**回测数据显示，基于 Stacking 架构的合成因子策略表现出了卓越的创收能力。其年化收益率达到 21.31%，较沪深 300 基准（8.37%）实现了约 13% 的超额年化回报。从净值曲线观察，红色的合成策略曲线自 2023 年起始终稳定运行于所有单因子和因子等权组合及基准之上。特别是在 2025 年 1 月的市场下行中，合成因子展现了极强的防御性，仅有小幅下跌，拉开了与其他策略的差距，证明其成功捕捉到了市场风格切换中的关键盈利窗口。
- **风险管理：**低回撤下的稳健增长在量化投资中，回撤控制是衡量策略生命力的核心指标。合成因子策略的最大回撤仅为 -12.11%，而同期基准回撤高达 -24.80%。尽管单因子 alpha_ret_std 具有略低回撤（-11.78%），但其收益率远低于合成策略。这说明 Stacking 模型并非简单地选择了低风险因子，而是通过多维因子的异构对冲，在获取高收益的同时，有效平滑了波动。策略在 2024 年初及 2025 年中的市场下行阶段均表现出了显著的抗跌性。
- **风险调整后收益：**Stacking 合成因子夏普比率为 1.35，是沪深 300 基准（0.33）的

4 倍以上，同时也显著高于表现最好的单因子（0.87）。这说明通过 XGBoost 与 LightGBM 的融合，模型不仅整合了单因子的线性预测力，还挖掘出了因子间的非线性共生关系。这种组合方式显著降低了单一因子在特定宏观环境下失效导致的系统性风险，从而在风险调整后收益这一维度上实现了对单因子的压制。

第四章 结论

本文通过构建基于机器学习 Stacking 集成架构的量化选股策略，深入探讨了多维因子非线性合成的有效性，并得出以下结论：

1. **集成学习显著提升预测边际：**实验证明，通过集成不同生长策略的树模型（XGBoost 的 Level-wise 与 LightGBM 的 Leaf-wise），可以有效对冲单一模型的归纳偏差。合成因子的均值 IC（6.58%）较表现最强的单因子（5.37%）提升了约 22%，综合预测评分（Score）提升显著，证明了集成架构在降噪与特征提取上的统计学优势。
2. **滚动建模有效应对风格漂移：**通过引入动态滚动窗口机制，模型能够及时学习并内化市场近期的逻辑变化。在测试集涵盖的风格剧烈切换期，策略依然保持了稳健的净值增长，夏普比率（1.35）达到基准指数（0.33）的 4 倍以上，体现了动态建模对“信噪比衰减”现象的有效抵抗。
3. **非线性 Alpha 来源具有可解释性：**特征重要性与 SHAP 解释分析表明，模型主要依赖波动率反转（‘alpha_ret_std’）、估值回归（‘alpha_eval_pe’）及换手率过热修正等逻辑获取超额收益。这说明 Stacking 模型成功捕捉到了 A 股市场因情绪过度反应而产生的定价偏差，并将其转化为长期稳健的 Alpha 溢价。
4. **策略稳健性与实战价值：**在长达三年的样本外回测中，策略以较低的回撤（-12.11%）实现了远超基准的年化收益（21.31%）。合成因子在单因子集体走弱的极端环境下表现出的“防御性”特征，证明了通过多模型、多因子异构对冲构建稳健投资组合的可行性。

综上所述，本文提出的基于机器学习的因子合成框架在实战维度上提供了高夏普、低回撤的选股方案。

参考文献

- [1] 孙健, 吴岚, 赵朝熠. 量化投资 [M]. 北京: 科学出版社, 2023.
- [2] 林晓明, 陈烨. 【华泰金工】人工智能 6: 人工智能选股之 Boosting 模型 [R]. 南京: 华泰证券研究所, 2017.
- [3] 林晓明, 陈烨. 【华泰金工】人工智能 9: 人工智能选股之循环神经网络模型 [R]. 南京: 华泰证券研究所, 2017.
- [4] 林晓明, 陈烨. 【华泰金工】人工智能 11: 人工智能选股之 stacking 集成学习 [R]. 南京: 华泰证券研究所, 2018.
- [5] 林晓明, 陈烨. 【华泰金工】人工智能 17: 人工智能选股之数据标注方法实证 [R]. 南京: 华泰证券研究所, 2019.