

第 7 次作业：滤波与择时

一、计算技术指标和滤波方法

我参考书上的图 3.1 到 3.9，其中图 3.5 和 3.6 不是技术指标，排除在外，另外图 3.10 是 Kalman 滤波，也补充进来，下面分别计算技术指标和几种滤波方法。

1.1 技术指标



图 1: 简单均线



图 2: 布林带




图 3: RSI 指标




图 4: KDJ 指标




图 5: 指数均线系数




图 6: 双均线系数

1.2 滤波方法




图 7: HP 滤波



图 8: L1 滤波




图 9: Fourier 滤波

二、优劣性总结

2.1 技术指标的优劣

根据课堂内容，技术指标可以分为两类：一类用于判断未来一段时间的趋势，例如均线；另一类用于刻画价格偏离趋势后的反转，例如 RSI、KDJ 和布林带。

均线指标能够起到降噪和平滑的作用。从第 1 问结果看，20 日均线比 60 日均线更加贴近收盘价，能够较快反映价格短期变化；60 日均线更加平滑，更适合观察中长期趋势。但缺点也很明显，也就是存在滞后性。当价格发生快速反转时，均线往往不能及时捕捉拐点，这会导致择时信号延迟。

布林带能够同时反映价格趋势、波动区间和当前价格位置。从图中可以看到，当价格波动加大时，布林带上下轨之间的距离会扩大；当价格接近上轨或下轨时，可以反映价格相对中枢的位置。因此，布林带既可以作为趋势指标，也可以作为反转指标。优点是能够刻画价格是否偏离正常波动区间；缺点是当市场处于趋势较强的行情时（如图 25 年 7 月到 8 月），价格可能几乎和上轨或下轨重合，这时候不能理解为超买或者超卖。

RSI 和 KDJ 属于反转和动量指标，能够反映短期上涨或下跌力量。从图像结果看，RSI 和 KDJ 对价格短期波动反应比较敏感，能够帮助判断市场是否处于较强上涨或较强下跌状态。这类指标的优点是反应快，适合捕捉短期变化；缺点是噪声很大，在震荡市场中频繁发出信号，在趋势行情中也可能长时间处于高位或低位，导致反转信号失效。

2.2 滤波方法的优劣

根据课堂内容，滤波本质上是将原始价格序列通过某种数学变换转化为新的序列，以发现价格中的长期趋势、周期性规律或隐含状态。与技术指标相比，滤波方法更强调

从序列中分离“信号”和“噪声”。

HP 滤波反映趋势，较小的 λ 值对应的趋势线更加贴近原始价格，较大的 λ 值则更加平滑，更能反映长期趋势。缺点是对参数 λ 比较敏感，不同 λ 会得到不同的趋势结果；同时，如果对完整样本一次性计算，容易引入未来信息，所以在预测任务中要用滚动窗口方式计算。

L1 更强调保留趋势中的结构性变化。从第 1 问结果看，L1 滤波后的趋势线较好地跟随了价格的主要走势，同时减少了部分短期波动。缺点是图中显示滤波和价格本身的差异不大，可能会存在滞后性。

Fourier 滤波能够识别价格中的周期性和低频趋势，缺点是金融价格序列通常突发事件和变化较多，因此 Fourier 滤波过于光滑，对拐点和非周期性冲击的刻画能力有限。

2.3 技术指标和滤波方法的比较

技术指标更侧重于构造具体、可解释的交易信号，比如趋势、反转、超买超卖和价格相对位置；滤波方法更侧重于从原始价格序列中提取较稳定的趋势和周期结构，降低噪声的影响。

从优点看，技术指标简单直观、计算方便，适合直接形成择时信号；滤波方法能够更好地分离信号与噪声，适合用于趋势分解和特征工程。从缺点看，技术指标容易滞后或产生虚假信号，滤波方法则依赖参数设定，且如果使用不当可能引入未来信息。它们大多来自于价格数据，无法反映基本面情况和事件，如果用于预测可能需要更多的信息补充。

三、预测方法改进

两个方向，其一是加入新信息（基本面、事件等），其二是尝试引入机器学习方法改进预测。下面一步步进行改进。

3.1 阶段 1：指标 + 滤波 + 线性回归

首先是基准模型，只用第一问计算得到的技术指标和滤波作为特征值，线性回归预测后一天的收益率。2025 年前作为训练集，2025 年后作为测试集。由于第一问计算的滤波用到全数据的信息，为了避免未来信息，这里重新滚动计算， t 时刻的滤波结果只用 t 时刻及以前的数据计算。




图 10: 阶段 1: 基准模型

表 1: 阶段 1 预测效果

模型	RMSE	MAE	R^2	方向准确率
阶段 1: 基准模型	0.011301	0.007799	-0.054057	0.495238

预测收益率比较平滑，基本围绕 0 附近波动，而真实收益率波动更大，说明基准模型对短期剧烈波动的捕捉能力比较弱。整体来看，只使用技术指标和滚动滤波特征时，线性回归模型的预测效果一般，方向判断接近随机水平，因此后面需要继续加入新信息并尝试其他模型进行改进。

3.2 阶段 2: 指标 + 滤波 + 新信息 + 线性回归

第二阶段，我们选择第一个改进方向，加入新信息。这里加入了交易特征（包括 volume, money 以及计算出来的相关特征）和事件特征（月份、星期等特征），继续线性回归预测后一天的收益率。




图 11: 阶段 2: 新信息

表 2: 阶段 1、2 预测效果对比

模型	RMSE	MAE	R^2	方向准确率
阶段 1: 基准模型	0.011301	0.007799	-0.054057	0.495238
阶段 2: 增加新信息	0.011229	0.008005	-0.040730	0.473016

加入交易信息和事件变量后，预测收益率的波动比阶段 1 略有增加，说明新信息对模型预测结果产生了一定影响。但整体上预测值仍然比较平滑，无法很好捕捉真实收益率中的大幅波动。

阶段 2 的 RMSE 略有下降， R^2 也从 -0.054057 改善到 -0.040730，说明加入新信息后模型的数值预测效果有小幅提升。但是 MAE 从 0.007799 上升到 0.008005，方向准确率从 0.495238 下降到 0.473016，说明新信息并没有稳定改善收益率方向的判断。整体来看，交易信息和事件变量提供了一些额外信息，但在线性回归模型下提升有限。

3.3 阶段 3: 指标 + 滤波 + 新信息 + Ridge 岭回归

第三阶段，我们选择第二个改进方向，更改模型。首先我们选择改进先前的线性模型，采用 Ridge 岭回归，避免过拟合。




图 12: 阶段 3: Ridge 岭回归

表 3: 阶段 1、2、3 预测效果对比

模型	RMSE	MAE	R^2	方向准确率
阶段 1: 基准模型	0.011301	0.007799	-0.054057	0.495238
阶段 2: 增加新信息	0.011229	0.008005	-0.040730	0.473016
阶段 3: Ridge 岭回归	0.011025	0.007437	-0.003193	0.504762

Ridge 岭回归的预测结果比阶段 2 更加平滑，预测值主要集中在 0 附近。这说明加入正则化后，模型减少了对噪声的过度拟合。

阶段 3 的 RMSE 下降到 0.011025，MAE 下降到 0.007437， R^2 也提升到 -0.003193，方向准确率提高到 0.504762。相比阶段 1 和阶段 2，Ridge 岭回归在大部分指标上都有改善，说明正则化对线性模型有一定帮助。

3.4 阶段 4: 指标 + 滤波 + 新信息 + 随机森林

第四阶段，我们尝试把线性模型改为树模型的机器学习方法，这里只选择随机森林进行测试。训练集和测试集不变，超参数调优后选择最佳参数，进行测试集的回测。




图 13: 阶段 4: 随机森林

表 4: 阶段 1、2、3、4 预测效果对比

模型	RMSE	MAE	R^2	方向准确率
阶段 1: 基准模型	0.011301	0.007799	-0.054057	0.495238
阶段 2: 增加新信息	0.011229	0.008005	-0.040730	0.473016
阶段 3: Ridge 岭回归	0.011025	0.007437	-0.003193	0.504762
阶段 4: 随机森林	0.011016	0.007452	-0.001500	0.473016

随机森林模型的预测值仍然主要围绕 0 附近波动，整体过于保守，不能很好捕捉真实收益率中的大幅变化。虽然随机森林可以刻画非线性关系，但仍然难以预测短期剧烈波动。

阶段 4 的 RMSE 为 0.011016，略低于前三个阶段， R^2 也提升到 -0.001500，是四个模型中最接近 0 的结果，说明随机森林在数值误差上有小幅改善。但是 MAE 略高于 Ridge，方向准确率为 0.473016，低于阶段 3。整体来看，随机森林对收益率大小的预测略有提升，但方向判断没有改善，说明非线性模型有一定帮助，但提升仍然有限。