

量化交易作业 1

一、简单回答以下问题：

1.1 对量化投资的理解

按照课上所学，量化投资是指借助数学、计算机的工具，对历史数据进行分析，得到市场蕴含的规律，进而获得投资策略，实现稳定且较高的收益。在此之后，我们把策略转换成可执行的程序，借助计算机的帮助实现自动化交易，而后面这个过程称为量化交易。“量化”是相较于“主观”而言的，我们需要将投资选择表现为客观的度量，比如需要从数据出发，借助数学、统计等相关知识进行分析和定量描述，最终由计算机执行。

1.2 选这门课的主要目的

一个目的是想了解量化投资的基本方法，即怎样构建一个投资策略，因为这部分知识在网络上很碎片化，而我已经学习了数学、统计和计算机的相关知识，想通过这门课了解量化投资的完整框架，为后续的实习工作做准备。

另一个目的是想参与到具体的实证分析项目中，来提升我的实践能力和 Coding 能力。此前我接触过与量化投资强相关的项目很少，因此这门课能为我提供很多有价值的题目去思考和练习。

1.3 专业背景：本科专业，目前的职业规划

我的本科专业是金融数学，现在对策略研究和衍生品相关内容比较感兴趣。

关于未来的职业规划，我希望将来能参与到量化策略研究的工作中。我已经学习了数学方面的概率统计和随机过程内容，计算机方面的算法和数据分析内容，还需要通过这门课和后续课程了解量化投资的框架、衍生品知识、优化方法等内容，并参与到一些企业的实习中，进一步确定自己想选择的方向。

二、编程建模

2.1 基本统计量

首先，我通过 Python 的 Pandas 库导入数据。股票类中，为了区分不同行业的股票差别，让研究尽可能体现股票市场的整体特征，而非单一行业的结果，我选择从 5 个不同的 Wind 一级行业中分别选择 2022 年 9 月 2 日总市值最高的股票，选择结果为：金融行业的工商银行，能源行业的中国石油，材料行业的万华化学，房地产行业的保利发展，日常消费行业的贵州茅台。期货类中，我选择反映市场情况的沪深 300 期货主力日数据进行分析。期权类中，我选择上证 50ETF 认购期权 1 分钟中的 50ETF 购 9 月 2850 进行分析。市场指数类中，我继续选择反映市场情况的沪深 300 指数日数据。最后在指数 ETF 类中，我选择上证 50ETF 日数据。

然后我对数据进行清洗，将原始数据中的“0”（缺失）转换为 np.nan 形式，在后续数值计算中忽略，最后分别对每一只证券用 Numpy 库进行统计量的计算，如下表所示：

表 1: 股票收益率统计描述

	工商银行	中国石油	万华化学	保利发展	贵州茅台
均值	0.000153	-0.000187	0.000685	0.000410	0.000941
中位数	0.000000	0.000000	0.000000	0.000000	0.000270
标准差	0.012867	0.015475	0.024380	0.025743	0.019648
偏度	0.004247	0.006797	-0.026884	0.056562	0.015606
超额峰度	11.318806	9.174149	2.103996	2.453718	2.328405
最大值	0.095310	0.095636	0.095557	0.095654	0.095310
最小值	-0.105134	-0.105244	-0.105573	-0.105662	-0.105361
自相关系数	-0.007732	-0.004141	0.009093	0.020617	0.005697

表 2: 期货与指数收益率统计描述

	沪深 300 期货	上证 50ETF 认购期权	沪深 300 指数	上证 50ETF
均值	0.000054	-0.000248	0.000223	0.000337
中位数	-0.000053	0.000000	0.000607	0.000000
标准差	0.015929	0.012603	0.016271	0.016916
偏度	-0.413533	-0.231265	-0.407997	-0.155948
超额峰度	7.006755	12.004028	4.197966	5.070942
最大值	0.097371	0.136393	0.089748	0.095780
最小值	-0.106357	-0.147901	-0.096952	-0.105455
自相关系数	-0.003339	-0.076077	0.023000	-0.010648

可以看出，第一，各类资产的均值接近于 0，说明收益更多表现为随机波动，而非稳定的结果。第二，各类资产的标准差远大于均值，这说明短期收益波动远强于平均收益，收益变化主要由波动主导。股票里万华化学和保利发展的标准差最大，说明材料行业和房地产行业的波动率更明显，而银行最稳定，进而说明行业对股票收益率的变化有影响。第三，各类资产的偏度整体接近于 0，但部分资产尤其是指数和衍生品的偏度为负，说明需要警惕这些资产的负收益风险。第四，各类资产的峰度较高，所有资产的超额峰度均大于 0，说明其收益率有尖峰、厚尾的特点，也就是说收益率集中在均值，但极端收益率出现的概率大于正态分布情形。第五，对比最大值与最小值，说明负向收益的极端值大于正向收益，因此负收益的风险更大。第六，自相关系数均接近于 0，说明股票收益率的线性预测性较低。

2.2 收益率分布

对于上一问所选择的各个资产，我使用 Matplotlib 库对收益率分布进行可视化，并绘制相同期望、方差的正态分布曲线与之对比：




图 3: 各资产对数收益率分布与正态拟合

先观察图像，所有资产的频率分布均接近正态分布的形式，大量数据在均值附近，但均呈现出与正态分布不同的尖峰特点，且个别资产出现长尾的现象。

接着，我们对所有资产的收益率分布进行 Jarque-Bera 检验，确认其是否符合正态分布，结果如下表：

表 3: 各资产收益率的偏度、峰度及 Jarque-Bera 正态性检验结果

资产	偏度	超额峰度	JB 统计量	p 值
工商银行	0.004247	11.318806	16377.181094	$< 10^{-300}$
中国石油	0.006797	9.174149	10758.091901	$< 10^{-300}$
万华化学	-0.026884	2.103996	565.400201	1.68×10^{-123}
保利发展	0.056562	2.453718	770.320567	5.33×10^{-168}
贵州茅台	0.015606	2.328405	692.236670	4.82×10^{-151}
沪深 300 期货	-0.413533	7.006755	6221.135394	$< 10^{-300}$
上证 50ETF 认购期权	-0.231265	12.004028	36306.263269	$< 10^{-300}$
沪深 300 指数	-0.407997	4.197966	3812.072327	$< 10^{-300}$
上证 50ETF	-0.155948	5.070942	4575.861866	$< 10^{-300}$

从检验结果可以看出， p 值远小于显著性水平 0.05，说明拒绝原假设，收益率分布不服从正态分布，另外由于超额峰度均大于 0（这里计算用的是 Pandas 库中的 kurt() 函数），说明收益率分布的确具有尖峰、厚尾的特点，与图像观察的结果一致。

2.3 价格时间序列

基于第（1）问选择的各类资产，我使用 Matplotlib 库对价格曲线进行可视化如下。



图 4: 工商银行价格时间序列



图 5: 中国石油价格时间序列



图 6: 万华化学价格时间序列




图 7: 保利发展价格时间序列




图 8: 贵州茅台价格时间序列

如上图，股票类的价格曲线在不同阶段有趋势的平稳变换和突变。万华化学和贵州茅台整体呈现较强的长期上涨，均在 2021 年前后达到高点，之后出现回落；保利发展在长期上涨的过程中波动率较大，工商银行则波动率相对较小，分别在 2021 年和 2018 年达到高点；中国石油则存在着长期下跌趋势，但在 2015 年前后出现暴涨和迅速下跌。因此，不同行业的股票在长期趋势和短期波动均存在明显差异。



图 9: 沪深 300 指数价格时间序列



图 10: 沪深 300 期货价格时间序列




图 11: 上证 50ETF 价格时间序列

如上图，相较于股票，沪深 300 指数、沪深 300 期货和上证 50ETF 的价格波动更加剧烈，但呈现出一定的同步趋势，在 2008 年、2015 年和 2020 年前后均出现明显的高点，之后出现暴跌回落；说明指数、ETF 和股指期货之间有一定的相关性。虽然沪深 300 指数和上证 50ETF 跟踪的标的不完全一致，但二者都能反映市场的整体趋势，因此一致性较高是合理的。




图 12: 上证 50ETF 认购期权价格时间序列

如上图，上证 50ETF 认购期权价格整体呈现下降趋势，伴随着波动，与前面的股票和其他资产价格变动不同，可能是由于期权随着接近到期日，价格也逐渐衰减的原因。

总的来说，金融资产价格首先受到种类的影响，不同种类的资产由于机制不同，存在明显差异；其次，单一资产的价格变动有阶段特征，但不同资产中出现价格剧烈变动的时刻具有一定的同步性，说明整体的经济环境会对资产造成较大的影响。

2.4 进阶 1：同一指数、ETF 和期货的收益率序列关系

我选择上证 50 指数进行考虑，通过 Numpy 库计算并绘制三者的收益率序列的相关性矩阵。如下图可以看出，三者收益率序列呈现出极高的相关性，因为三者追踪的都是上证 50 的标的，这印证了 ETF 和期货价格依赖于标的变量。但相关性达不到 1，说明受到交易机制的影响，资产价格也会发生变化。

表 4: 上证 50、上证 50ETF 与上证 50 期货收益率相关系数

	上证 50	上证 50ETF	上证 50 期货
上证 50	1.00	0.99	0.95
上证 50ETF	0.99	1.00	0.96
上证 50 期货	0.95	0.96	1.00

2.5 进阶 2：不同股票、期货的同期收益率的相关性

首先我们选择第 1 问的 5 只不同行业的股票，通过 Numpy 库计算收益率并绘制相关性矩阵如下：

表 5: 股票收益率相关系数矩阵

	工商银行	中国石油	万华化学	保利发展	贵州茅台
工商银行	1.00	0.36	0.29	0.48	0.27
中国石油	0.36	1.00	0.34	0.29	0.12
万华化学	0.29	0.34	1.00	0.41	0.39
保利发展	0.48	0.29	0.41	1.00	0.22
贵州茅台	0.27	0.12	0.39	0.22	1.00

可以看出, 由于这 5 只股票来自不同的行业, 其相关性相对较低, 均在 0.5 以下, 说明行业对股票收益率的变化有不小的影响。接下来去除行业的影响, 我们分别选择这五个行业内部的 5 只股票, 再次计算收益率并绘制收益率相关性矩阵如下:

表 6: 金融行业股票收益率相关系数

	工商银行	建设银行	农业银行	中国银行	招商银行
工商银行	1.00	0.84	0.85	0.81	0.66
建设银行	0.84	1.00	0.84	0.81	0.70
农业银行	0.85	0.84	1.00	0.85	0.66
中国银行	0.81	0.81	0.85	1.00	0.63
招商银行	0.66	0.70	0.66	0.63	1.00

表 7: 能源行业股票收益率相关系数

	中国石油	中国神华	中国石化	兖矿能源	陕西煤业
中国石油	1.00	0.57	0.81	0.47	0.44
中国神华	0.57	1.00	0.60	0.69	0.69
中国石化	0.81	0.60	1.00	0.47	0.47
兖矿能源	0.47	0.69	0.47	1.00	0.75
陕西煤业	0.44	0.69	0.47	0.75	1.00

表 8: 材料行业股票收益率相关系数

	万华化学	紫金矿业	天齐锂业	恩捷股份	赣锋锂业
万华化学	1.00	0.34	0.24	0.20	0.30
紫金矿业	0.34	1.00	0.28	0.12	0.32
天齐锂业	0.24	0.28	1.00	0.34	0.73
恩捷股份	0.20	0.12	0.34	1.00	0.44
赣锋锂业	0.30	0.32	0.73	0.44	1.00

表 9: 房地产行业股票收益率相关系数

	保利发展	万科 A	招商蛇口	金地集团	新城控股
保利发展	1.00	0.70	0.77	0.77	0.66
万科 A	0.70	1.00	0.59	0.68	0.58
招商蛇口	0.77	0.59	1.00	0.67	0.61
金地集团	0.77	0.68	0.67	1.00	0.58
新城控股	0.66	0.58	0.61	0.58	1.00

表 10: 日常消费行业股票收益率相关系数

	贵州茅台	五粮液	海天味业	山西汾酒	泸州老窖
贵州茅台	1.00	0.77	0.48	0.62	0.71
五粮液	0.77	1.00	0.51	0.72	0.81
海天味业	0.48	0.51	1.00	0.49	0.49
山西汾酒	0.62	0.72	0.49	1.00	0.73
泸州老窖	0.71	0.81	0.49	0.73	1.00

通过这 5 个行业内部的股票相关性矩阵可以看出，大部分股票收益率的相关性明显提升到 0.5 以上，进一步验证了行业对股票收益率确实有较大影响。

具体来看，金融行业和房地产行业的股票收益率相关性最高，相关系数均在 0.5 以上，说明这两类行业受到市场的整体影响较大；能源行业、日常消费行业股票收益率相关性中等，材料行业相关性较低，说明行业内部也存在一定的差异。

接下来我们选择 4 个不同品种的期货进行相关性分析，根据股票相关性分析的结果，即行业对股票收益率的影响，再加上期货依赖于标的资产，这里得到的相关性也应该较低。绘制相关性矩阵如下：

表 11: 商品期货收益率相关系数矩阵

	动力煤	豆粕	沪镍	螺纹钢
动力煤	1.00	-0.01	0.05	-0.01
豆粕	-0.01	1.00	0.37	0.19
沪镍	0.05	0.37	1.00	0.42
螺纹钢	-0.01	0.19	0.42	1.00

如图，期货收益率序列之间的确呈现出较低的相关性，甚至低于 0.1，说明除了标的资产的影响，期货还因为交易机制等其他因素，不同品种之间的相关性进一步降低。